



Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Tecnologías para la Inteligencia de Negocios

Dr. Ricardo Valdivia Pinto
`rvaldivi@academicos.uta.cl`

Facultad de Ingeniería
Departamento de Ingeniería en Computación e Informática
Universidad de Tarapacá
Arica - Chile

Inteligencia de Negocios '2023



Índice

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

1 Diseño Físico DW

2 Proceso ETL

3 Extracción

4 Transformación

5 Carga



Índice

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

1 Diseño Físico DW

2 Proceso ETL

3 Extracción

4 Transformación

5 Carga



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tablas de Dimensión:

- Cree una restricción de clave primaria sobre las claves subrogadas (crea un índice único).
- Cree una restricción de unicidad sobre las claves operacionales (creará un índice único). En el caso de una SCD tipo 2 hay que considerar la validez como parte de la clave (`valid_from`).
- Usualmente no se requiere crear índices adicionales sobre las tablas de dimensión.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tablas de Dimensión:

- Cree una restricción de clave primaria sobre las claves subrogadas (crea un índice único).
- Cree una restricción de unicidad sobre las claves operacionales (creará un índice único). En el caso de una SCD tipo 2 hay que considerar la validez como parte de la clave (`valid_from`).
- Usualmente no se requiere crear índices adicionales sobre las tablas de dimensión.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tablas de Dimensión:

- Cree una restricción de clave primaria sobre las claves subrogadas (crea un índice único).
- Cree una restricción de unicidad sobre las claves operacionales (creará un índice único). En el caso de una SCD tipo 2 hay que considerar la validez como parte de la clave (`valid_from`).
- Usualmente no se requiere crear índices adicionales sobre las tablas de dimensión.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tablas de Dimensión:
 - Cree una restricción de clave primaria sobre las claves subrogadas (crea un índice único).
 - Cree una restricción de unicidad sobre las claves operacionales (creará un índice único). En el caso de una SCD tipo 2 hay que considerar la validez como parte de la clave (`valid_from`).
 - Usualmente no se requiere crear índices adicionales sobre las tablas de dimensión.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tabla de Hechos:

- Cree una restricción para cada clave foránea (rely disable/enable) y un índice bitmap sobre cada una de ellas.
- Cree restricciones de no nulidad para cada clave foránea (usualmente las medidas también son no nulas).
- Usualmente no se requiere una restricción de clave primaria en la tabla de hechos.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tabla de Hechos:

- Cree una restricción para cada clave foránea (rely disable/enable) y un índice bitmap sobre cada una de ellas.
- Cree restricciones de no nulidad para cada clave foránea (usualmente las medidas también son no nulas).
- Usualmente no se requiere una restricción de clave primaria en la tabla de hechos.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tabla de Hechos:
 - Cree una restricción para cada clave foránea (rely disable/enable) y un índice bitmap sobre cada una de ellas.
 - Cree restricciones de no nulidad para cada clave foránea (usualmente las medidas también son no nulas).
 - Usualmente no se requiere una restricción de clave primaria en la tabla de hechos.



Implementación ROLAP - Oracle

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Tabla de Hechos:

- Cree una restricción para cada clave foránea (rely disable/enable) y un índice bitmap sobre cada una de ellas.
- Cree restricciones de no nulidad para cada clave foránea (usualmente las medidas también son no nulas).
- Usualmente no se requiere una restricción de clave primaria en la tabla de hechos.



Implementación ROLAP


Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga





Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

```
-- primary key rely
alter table dim_products
add constraint dim_products_pk
primary key(pk_products) rely

-- foreign key rely
alter table fact_superstore
add constraint fact_superstore_dim_products_fk
foreign key(fk_products)
references dim_products(pk_products)
rely disable novalidate

-- posterior al proceso etl
alter table fact_superstore
modify constraint fact_superstore_dim_products_fk
enable novalidate
```



Índices

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- **Índices B-trees:** opción por defecto, útil para verificar unicidad o búsqueda por rango, ideal para ambientes OLTP.
- **Índices Bitmap:** ocupan poco espacio, preferibles para atributos con baja cardinalidad, consultas que involucran atributos de baja cardinalidad (where), ideal para ambientes OLAP.
- **Otros índices:** índices por múltiples atributos, índices basados en funciones, índices bitmap join, índices particionados, ...



- **Índices B-trees:** opción por defecto, útil para verificar unicidad o búsqueda por rango, ideal para ambientes OLTP.
- **Índices Bitmap:** ocupan poco espacio, preferibles para atributos con baja cardinalidad, consultas que involucran atributos de baja cardinalidad (where), ideal para ambientes OLAP.
- **Otros índices:** índices por múltiples atributos, índices basados en funciones, índices bitmap join, índices particionados, ...



Índices

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- **Índices B-trees:** opción por defecto, útil para verificar unicidad o búsqueda por rango, ideal para ambientes OLTP.
- **Índices Bitmap:** ocupan poco espacio, preferibles para atributos con baja cardinalidad, consultas que involucran atributos de baja cardinalidad (where), ideal para ambientes OLAP.
- **Otros índices:** índices por múltiples atributos, índices basados en funciones, índices bitmap join, índices particionados, ...



Índices

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- **Índices B-trees:** opción por defecto, útil para verificar unicidad o búsqueda por rango, ideal para ambientes OLTP.
- **Índices Bitmap:** ocupan poco espacio, preferibles para atributos con baja cardinalidad, consultas que involucran atributos de baja cardinalidad (where), ideal para ambientes OLAP.
- **Otros índices:** índices por múltiples atributos, índices basados en funciones, índices bitmap join, índices particionados, ...



Índices


Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga





Índices


Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga





Índices

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

```
-- unique constraint (índice b-tree implícito)
alter table dim_products
add constraint dim_products_uk
unique("Product Code")

-- índice bitmap
create bitmap index fact_superstore_fk_products_idx_bm
on fact_superstore(fk_products)
```



Índice

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

1 Diseño Físico DW

2 Proceso ETL

3 Extracción

4 Transformación

5 Carga



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

ETL

Es el proceso que permite a las organizaciones mover datos desde múltiples fuentes, reformatearlos y limpiarlos, y cargarlos en otra base de datos, data mart, o data warehouse para su análisis, o en otro sistema operacional para apoyar un proceso de negocios.



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

ETL

Es el proceso que permite a las organizaciones mover datos desde múltiples fuentes, reformatearlos y limpiarlos, y cargarlos en otra base de datos, data mart, o data warehouse para su análisis, o en otro sistema operacional para apoyar un proceso de negocios.



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- El proceso más subestimado en el desarrollo DW
- El proceso que consume más tiempo en el desarrollo DW
 - Sobre el 80 % del tiempo de desarrollo es gastado en el diseño ETL
- Extracción
 - Extraer datos relevantes
- Transformación
 - Limpieza de datos
 - Transformar datos al formato DW
 - Construir claves subrogadas
- Carga
 - Cargar datos en el DW
 - Poblar tablas de agregación



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- El proceso más subestimado en el desarrollo DW
- El proceso que consume más tiempo en el desarrollo DW
 - Sobre el 80 % del tiempo de desarrollo es gastado en el diseño ETL
- Extracción
 - Extraer datos relevantes
- Transformación
 - Limpieza de datos
 - Transformar datos al formato DW
 - Construir claves subrogadas
- Carga
 - Cargar datos en el DW
 - Poblar tablas de agregación



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- El proceso más subestimado en el desarrollo DW
- El proceso que consume más tiempo en el desarrollo DW
 - Sobre el 80 % del tiempo de desarrollo es gastado en el diseño ETL
- Extracción
 - Extraer datos relevantes
- Transformación
 - Limpieza de datos
 - Transformar datos al formato DW
 - Construir claves subrogadas
- Carga
 - Cargar datos en el DW
 - Poblar tablas de agregación



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- El proceso más subestimado en el desarrollo DW
- El proceso que consume más tiempo en el desarrollo DW
 - Sobre el 80 % del tiempo de desarrollo es gastado en el diseño ETL
- Extracción
 - Extraer datos relevantes
- Transformación
 - Limpieza de datos
 - Transformar datos al formato DW
 - Construir claves subrogadas
- Carga
 - Cargar datos en el DW
 - Poblar tablas de agregación



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- El proceso más subestimado en el desarrollo DW
- El proceso que consume más tiempo en el desarrollo DW
 - Sobre el 80 % del tiempo de desarrollo es gastado en el diseño ETL
- Extracción
 - Extraer datos relevantes
- Transformación
 - Limpieza de datos
 - Transformar datos al formato DW
 - Construir claves subrogadas
- Carga
 - Cargar datos en el DW
 - Poblar tablas de agregación



ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- El proceso más subestimado en el desarrollo DW
- El proceso que consume más tiempo en el desarrollo DW
 - Sobre el 80 % del tiempo de desarrollo es gastado en el diseño ETL
- Extracción
 - Extraer datos relevantes
- Transformación
 - Limpieza de datos
 - Transformar datos al formato DW
 - Construir claves subrogadas
- Carga
 - Cargar datos en el DW
 - Poblar tablas de agregación



Fases:

- Fase de Diseño
Diseño de proceso ETL
- Fase de Carga Inicial
Primer poblamiento del DW
- Fase de Carga Incremental
Mantener el DW actualizado con respecto a cambios en las fuentes de datos



Fases:

- Fase de Diseño
Diseño de proceso ETL
- Fase de Carga Inicial
Primer poblamiento del DW
- Fase de Carga Incremental
Mantener el DW actualizado con respecto a cambios en las fuentes de datos



Fases:

- Fase de Diseño
Diseño de proceso ETL
- Fase de Carga Inicial
Primer poblamiento del DW
- Fase de Carga Incremental
Mantener el DW actualizado con respecto a cambios en las fuentes de datos



Fases:

- Fase de Diseño
Diseño de proceso ETL
- Fase de Carga Inicial
Primer poblamiento del DW
- Fase de Carga Incremental
Mantener el DW actualizado con respecto a cambios en las fuentes de datos



ETL


Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga





Área de *Staging*

Un área de *stage* (área de pruebas o área de ensayo), también llamada zona de *landing* (zona de aterrizaje), es un área intermedia de almacenamiento de datos utilizada para el procesamiento de los mismos durante procesos de extracción, transformación y carga.



Área de *Staging*

Un área de *stage* (área de pruebas o área de ensayo), también llamada zona de *landing* (zona de aterrizaje), es un área intermedia de almacenamiento de datos utilizada para el procesamiento de los mismos durante procesos de extracción, transformación y carga.



El área de *staging* es ...

- Un área de almacenamiento transitorio de datos en el proceso ETL.
- Sin acceso a los usuarios.
- Implementada con tablas relacionales, archivos planos u otros.
- Util para consolidación de datos, estandarización, rendimiento, respaldo, detección de cambios, ...



El área de *staging* es ...

- Un área de almacenamiento transitorio de datos en el proceso ETL.
- Sin acceso a los usuarios.
- Implementada con tablas relacionales, archivos planos u otros.
- Util para consolidación de datos, estandarización, rendimiento, respaldo, detección de cambios, ...



El área de *staging* es ...

- Un área de almacenamiento transitorio de datos en el proceso ETL.
- Sin acceso a los usuarios.
- Implementada con tablas relacionales, archivos planos u otros.
- Util para consolidación de datos, estandarización, rendimiento, respaldo, detección de cambios, ...



El área de *staging* es ...

- Un área de almacenamiento transitorio de datos en el proceso ETL.
- Sin acceso a los usuarios.
- Implementada con tablas relacionales, archivos planos u otros.
- Util para consolidación de datos, estandarización, rendimiento, respaldo, detección de cambios, ...



El área de *staging* es ...

- Un área de almacenamiento transitorio de datos en el proceso ETL.
- Sin acceso a los usuarios.
- Implementada con tablas relacionales, archivos planos u otros.
- Util para consolidación de datos, estandarización, rendimiento, respaldo, detección de cambios, ...



- **Planificación**

- Realizar un diagrama de alto nivel del flujo origen-destino.
- Seleccionar y probar la herramienta ETL.
- Bosquejar las transformaciones complejas, la generación de claves subrogadas y la secuencia de trabajo para cada tabla de destino.



- **Planificación**

- Realizar un diagrama de alto nivel del flujo origen-destino.
- Seleccionar y probar la herramienta ETL.
- Bosquejar las transformaciones complejas, la generación de claves subrogadas y la secuencia de trabajo para cada tabla de destino.



- **Planificación**

- Realizar un diagrama de alto nivel del flujo origen-destino.
- Seleccionar y probar la herramienta ETL.
- Bosquejar las transformaciones complejas, la generación de claves subrogadas y la secuencia de trabajo para cada tabla de destino.



- **Planificación**

- Realizar un diagrama de alto nivel del flujo origen-destino.
- Seleccionar y probar la herramienta ETL.
- Bosquejar las transformaciones complejas, la generación de claves subrogadas y la secuencia de trabajo para cada tabla de destino.



● Construcción de Dimensiones

- Construcción y prueba de las dimensiones estáticas.
- Construcción y prueba de una dimensión cambiante.
- Construcción y prueba del resto de las dimensiones.



- **Construcción de Dimensiones**

- Construcción y prueba de las dimensiones estáticas.
- Construcción y prueba de una dimensión cambiante.
- Construcción y prueba del resto de las dimensiones.



- **Construcción de Dimensiones**

- Construcción y prueba de las dimensiones estáticas.
- Construcción y prueba de una dimensión cambiante.
- Construcción y prueba del resto de las dimensiones.



- **Construcción de Dimensiones**

- Construcción y prueba de las dimensiones estáticas.
- Construcción y prueba de una dimensión cambiante.
- Construcción y prueba del resto de las dimensiones.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Dimensiones Estáticas.
 - Construir el proceso de poblamiento.
- Gestión de dimensiones cambiantes.
 - Gestionar claves subrogadas a partir una clave de producción.
 - Gestionar actualización/inserción dependiendo del tipo de SCD.
- Poblamiento de dimensiones.
 - Dimensiones pequeñas: remplazar.
 - Dimensiones grandes: cargar solo cambios.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Dimensiones Estáticas.
 - Construir el proceso de poblamiento.
- Gestión de dimensiones cambiantes.
 - Gestionar claves subrogadas a partir una clave de producción.
 - Gestionar actualización/inserción dependiendo del tipo de SCD.
- Poblamiento de dimensiones.
 - Dimensiones pequeñas: remplazar.
 - Dimensiones grandes: cargar solo cambios.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Dimensiones Estáticas.
 - Construir el proceso de poblamiento.
- Gestión de dimensiones cambiantes.
 - Gestionar claves subrogadas a partir una clave de producción.
 - Gestionar actualización/inserción dependiendo del tipo de SCD.
- Poblamiento de dimensiones.
 - Dimensiones pequeñas: remplazar.
 - Dimensiones grandes: cargar solo cambios.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Dimensiones Estáticas.
 - Construir el proceso de poblamiento.
- Gestión de dimensiones cambiantes.
 - Gestionar claves subrogadas a partir una clave de producción.
 - Gestionar actualización/inserción dependiendo del tipo de SCD.
- Poblamiento de dimensiones.
 - Dimensiones pequeñas: remplazar.
 - Dimensiones grandes: cargar solo cambios.



Diseño ETL - Apache Hop

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Pipeline

Pipelines son los *data workers*. Las operaciones en un Pipeline leen, modifica, enriquecen, limpian y escriben datos. Las transformaciones en un Pipeline **son ejecutadas en paralelo**.

Workflow

Un Workflow es una secuencia de operaciones que **son ejecutadas secuencialmente**. Los Workflows usualmente no operan sobre los datos directamente, sino que ejecutan tareas de orquestación.



Diseño ETL - Apache Hop

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Pipeline

Pipelines son los *data workers*. Las operaciones en un Pipeline leen, modifica, enriquecen, limpian y escriben datos. Las transformaciones en un Pipeline **son ejecutadas en paralelo**.

Workflow

Un Workflow es una secuencia de operaciones que **son ejecutadas secuencialmente**. Los Workflows usualmente no operan sobre los datos directamente, sino que ejecutan tareas de orquestación.



Diseño ETL - Apache Hop

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Pipeline

Pipelines son los *data workers*. Las operaciones en un Pipeline leen, modifica, enriquecen, limpian y escriben datos. Las transformaciones en un Pipeline **son ejecutadas en paralelo**.

Workflow

Un Workflow es una secuencia de operaciones que **son ejecutadas secuencialmente**. Los Workflows usualmente no operan sobre los datos directamente, sino que ejecutan tareas de orquestación.



Pipeline


Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga





Workflow


Diseño Físico
DW

Proceso ETL

Extracción

Transformación


Carga





Dimensiones Estáticas

Dimension Date Pipeline





Dimensiones SCD (tipo 1)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Stage Orders Pipeline





Dimensiones SCD (tipo 1)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Insert/Update

- Se busca una fila en una tabla usando una o más *lookup keys*. Si no se encuentra la fila asociada a la clave, se inserta una nueva fila.
- Si se encuentra y los atributos a actualizar son similares, no se realiza nada.
- Si no son todos iguales, la fila se actualiza.



Dimensiones SCD (tipo 1)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Insert/Update

- Se busca una fila en una tabla usando una o más *lookup keys*. Si no se encuentra la fila asociada a la clave, se inserta una nueva fila.
- Si se encuentra y los atributos a actualizar son similares, no se realiza nada.
- Si no son todos iguales, la fila se actualiza.



Dimensiones SCD (tipo 1)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Insert/Update

- Se busca una fila en una tabla usando una o más *lookup keys*. Si no se encuentra la fila asociada a la clave, se inserta una nueva fila.
- Si se encuentra y los atributos a actualizar son similares, no se realiza nada.
- Si no son todos iguales, la fila se actualiza.



Dimensiones SCD (tipo 1)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga


Transformation Insert/Update

- Se busca una fila en una tabla usando una o más *lookup keys*. Si no se encuentra la fila asociada a la clave, se inserta una nueva fila.
- Si se encuentra y los atributos a actualizar son similares, no se realiza nada.
- Si no son todos iguales, la fila se actualiza.



Dimensiones SCD (tipo 1)

Dim Orders Pipeline



Insert / update

Transform name: DIM_ORDERS

Connection: INUTA

Target schema: RVALDIVIA

Target table: DIM_ORDERS

Commit size: 100

Don't perform any updates: ☐

The key(s) to look up the value(s):

#	Table field	Comparator	Stream field1	Stream field2
1	Order Code	=	Order Code	

Get fields

Update fields:

#	Table field	Stream field	Update
1	Order Code	Order Code	N
2	Order Priority	Order Priority	Y

Get update fields

Edit mapping

Help OK SQL Cancel

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Clave Primaria Autogenerada

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

```
-- primary key
```

```
CREATE TABLE DIM_ORDERS (  
  PK_ORDERS INTEGER GENERATED ALWAYS AS IDENTITY CONSTRAINT DIM_ORDERS_PK PRIMARY KEY,  
  "Order Code" INTEGER,  
  "Order Priority" VARCHAR2(50)  
)
```



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Stage Products Pipeline





Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:

a) Uno o más atributos son diferentes y tienen un **primary key** (Primary Type II). Un nuevo registro es insertado.

b) Uno o más atributos son diferentes y tienen un **secondary key** (Secondary Type II). El registro es actualizado en todos los segmentos del registro.

c) Uno o más atributos son diferentes y tienen un **segment**. Este segmento es actualizado en la última versión del registro.

d) Todos los atributos son iguales. No se insertan nuevos registros ni actualizaciones.



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:
 - Uno o más atributos son diferentes y tienen un *insert* (Kimball Type II): Un nuevo registro es insertado.
 - Los atributos son iguales y tienen un *update* (Kimball Type I): El registro existente es actualizado con los nuevos valores de los atributos.
 - Uno o más atributos son diferentes y tienen un *update* (Kimball Type III): El registro existente es actualizado con los nuevos valores de los atributos.
 - Los atributos son iguales y tienen un *delete* (Kimball Type IV): El registro existente es eliminado.



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:
 - Uno o más atributos son diferentes y tienen un *insert* (Kimball Type II): Un nuevo registro es insertado.
 - Uno o más atributos son diferentes y tienen un *punch through* (Kimball Type I): Estos atributos se actualizan en todas las versiones del registro.
 - Uno o más atributos son diferentes y tienen un *update*: Estos atributos se actualizan en la última versión del registro.
 - Todos los atributos son iguales: No se ejecutan actualizaciones ni inserciones.



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:
 - Uno o más atributos son diferentes y tienen un *insert* (Kimball Type II): Un nuevo registro es insertado.
 - Uno o más atributos son diferentes y tienen un *punch through* (Kimball Type I): Estos atributos se actualizan en todas las versiones del registro.
 - Uno o más atributos son diferentes y tienen un *update*: Estos atributos se actualizan en la última versión del registro.
 - Todos los atributos son iguales: No se ejecutan actualizaciones ni inserciones.



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:
 - Uno o más atributos son diferentes y tienen un *insert* (Kimball Type II): Un nuevo registro es insertado.
 - Uno o más atributos son diferentes y tienen un *punch through* (Kimball Type I): Estos atributos se actualizan en todas las versiones del registro.
 - Uno o más atributos son diferentes y tienen un *update*: Estos atributos se actualizan en la última versión del registro.
 - Todos los atributos son iguales: No se ejecutan actualizaciones ni inserciones.



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:
 - Uno o más atributos son diferentes y tienen un *insert* (Kimball Type II): Un nuevo registro es insertado.
 - Uno o más atributos son diferentes y tienen un *punch through* (Kimball Type I): Estos atributos se actualizan en todas las versiones del registro.
 - Uno o más atributos son diferentes y tienen un *update*: Estos atributos se actualizan en la última versión del registro.
 - Todos los atributos son iguales: No se ejecutan actualizaciones ni inserciones.



Dimensiones SCD (tipo 2)

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformation Dimension Lookup/Update

- Si los registros no son encontrados: se insertan en la tabla.
- Si los registros son encontrados y:
 - Uno o más atributos son diferentes y tienen un *insert* (Kimball Type II): Un nuevo registro es insertado.
 - Uno o más atributos son diferentes y tienen un *punch through* (Kimball Type I): Estos atributos se actualizan en todas las versiones del registro.
 - Uno o más atributos son diferentes y tienen un *update*: Estos atributos se actualizan en la última versión del registro.
 - Todos los atributos son iguales: No se ejecutan actualizaciones ni inserciones.



Dimensiones SCD (tipo 2)

Dimension Products Pipeline

Diagrama de flujo de datos:

```
graph LR; STG_PRODUCTS[STG_PRODUCTS] --> DIM_PRODUCTS[DIM_PRODUCTS]
```

Configuración de la transformación **Dimension lookup/update**:

- Transform name: DIM_PRODUCTS
- Update the dimension? ☒
- Connection: INUTA
- Target schema: RVALDIVIA
- Target table: DIM_PRODUCTS
- Commit size: 100
- Enable the cache? ☒
- Pre-load the cache? ☐
- Cache size in rows (0 = cache): 5000

pestañas: Keys | Fields | Technical key | Versioning

Key fields (to look up row in dimension):

#	Dimension field	Field in stream
1	Product Code	Product Code

Botones: ? Help, OK, Get Fields, SQL, Cancel

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Dimensiones SCD (tipo 2)

Dimension Products Pipeline

Diagrama de flujo: STG_PRODUCTS → DIM_PRODUCTS

Dimension lookup/update

Transform name: DIM_PRODUCTS

Update the dimension? ☒

Connection: INUTA

Target schema: RVALDIVIA

Target table: DIM_PRODUCTS

Commit size: 100

Enable the cache? ☒

Pre-load the cache? ☐

Cache size in rows (0 = cache all): 5000

Keys Fields Technical key Versioning

Lookup/Update fields

#	Dimension field	Stream field to compare with	Type of dimension update
1	Product Category	Product Category	Insert
2	Product Sub-Category	Product Sub-Category	Insert
3	Product Name	Product Name	Update
4	Product Container	Product Container	Punch through

Help OK Get Fields SQL Cancel

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Dimensiones SCD (tipo 2)

Dimension Products Pipeline

Diagrama de flujo: STG_PRODUCTS → DIM_PRODUCTS

Dimension lookup/update

Transform name: DIM_PRODUCTS

Update the dimension? ☒

Connection: INUTA

Target schema: RVALDIVIA

Target table: DIM_PRODUCTS

Commit size: 100

Enable the cache? ☒

Pre-load the cache? ☐

Cache size in rows (0 = cache all): 5000

Keys Fields Technical key Versioning

Technical key field: PK_PRODUCTS New name:

Creation of technical key

☒ Use table maximum + 1

☐ Use sequence

☐ Use auto increment field

Help OK Get Fields SQL Cancel

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Dimensiones SCD (tipo 2)

Dimension Customers Pipeline

Diagrama de flujo: STG_CUSTOMERS → DIM_CUSTOMERS

Dimension lookup/update

Transform name: DIM_CUSTOMERS

Update the dimension? ☒

Connection: INUTA

Target schema: RVALDIVIA

Target table: DIM_CUSTOMERS

Commit size: 100

Enable the cache? ☒

Pre-load the cache? ☐

Cache size in rows (0 = cache all): 5000

Keys Fields Technical key Versioning

Technical key field: PK_CUSTOMERS New name:

Creation of technical key

☐ Use table maximum + 1

☒ Use sequence: DIM_CUSTOMERS_SEQ

☐ Use auto increment field

Help OK Get Fields SQL Cancel

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Sequence

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

```
-- sequence
```

```
CREATE SEQUENCE dim_customers_seq  
  START WITH      1  
  INCREMENT BY    1  
  CACHE 10000;  
)
```



Dimensiones SCD (tipo 2)

Dimension Products Pipeline

Diagrama de flujo: STG_PRODUCTS → DIM_PRODUCTS

Dimension lookup/update

Transform name: DIM_PRODUCTS

Update the dimension? ☒

Connection: INUTA

Target schema: RVALDIVIA

Target table: DIM_PRODUCTS

Commit size: 100

Enable the cache? ☒

Pre-load the cache? ☐

Cache size in rows (0 = cache all): 5000

Keys Fields Technical key Versioning

Version field: version

Stream Datefield:

Date range start field: date_from Min. year: 1900

Use an alternative start date? ☐ <Select Option>

Table date range end: date_to Max. year: 2199

Help OK Get Fields SQL Cancel

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



● Construcción de las Tablas de Hechos

- Construcción y prueba del poblamiento inicial.
- Construcción y prueba de la carga incremental.
- Construcción y prueba de las tablas de agregados.



- **Construcción de las Tablas de Hechos**
 - Construcción y prueba del poblamiento inicial.
 - Construcción y prueba de la carga incremental.
 - Construcción y prueba de las tablas de agregados.



- **Construcción de las Tablas de Hechos**
 - Construcción y prueba del poblamiento inicial.
 - Construcción y prueba de la carga incremental.
 - Construcción y prueba de las tablas de agregados.



- **Construcción de las Tablas de Hechos**

- Construcción y prueba del poblamiento inicial.
- Construcción y prueba de la carga incremental.
- Construcción y prueba de las tablas de agregados.



Tabla de Hechos

Fact SuperStore Pipeline

Diagrama de flujo del pipeline Fact SuperStore:

```
graph LR; STG_SUPERSTORE --> LOOK_ORDERS; LOOK_ORDERS --> LOOK_PRODUCTS; LOOK_PRODUCTS --> LOOK_CUSTOMERS; LOOK_CUSTOMERS --> LOOK_DATE; LOOK_DATE --> SEL_SUPERSTORE; SEL_SUPERSTORE --> FACT_SUPERSTORE;
```

Configuración de la transformación Database lookup:

- Transform name: LOOK_ORDERS
- Connection: INUTA
- Lookup schema: RVALDIVIA
- Lookup table: DIM_ORDERS
- Enable cache?: ☐
- Cache size in rows (0=cache everything): 0
- Load all data from table: ☐

The key(s) to look up the value(s):

#	Table field	Comparator	Field1	Field2
1	Order Code	=	Order Code	

Values to return from the lookup table:

#	Field	New name	Default	Type	Trim type
1	PK_ORDERS	FK_ORDERS		Integer	none

Diseño Físico
DW

Proceso ETL

Extracción


Transformación

Carga



Tabla de Hechos

Fact SuperStore Pipeline



Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Carga inicial
 - ETL para todos los datos hasta ahora.
 - Se realiza cuando el DW se puebla la primera vez.
 - Muy pesado - grandes volúmenes de datos.
- Carga incremental
 - Mover solo los cambios desde la última carga.
 - Se realiza periódicamente después del inicio de DW.
 - Menos pesado - volúmenes de datos más pequeños.
- Las dimensiones deben actualizarse **antes** que los hechos.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Carga inicial
 - ETL para todos los datos hasta ahora.
 - Se realiza cuando el DW se puebla la primera vez.
 - Muy pesado - grandes volúmenes de datos.
- Carga incremental
 - Mover solo los cambios desde la última carga.
 - Se realiza periódicamente después del inicio de DW.
 - Menos pesado - volúmenes de datos más pequeños.
- Las dimensiones deben actualizarse **antes** que los hechos.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Carga inicial
 - ETL para todos los datos hasta ahora.
 - Se realiza cuando el DW se puebla la primera vez.
 - Muy pesado - grandes volúmenes de datos.
- Carga incremental
 - Mover solo los cambios desde la última carga.
 - Se realiza periódicamente después del inicio de DW.
 - Menos pesado - volúmenes de datos más pequeños.
- Las dimensiones deben actualizarse **antes** que los hechos.



Diseño ETL

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Carga inicial
 - ETL para todos los datos hasta ahora.
 - Se realiza cuando el DW se puebla la primera vez.
 - Muy pesado - grandes volúmenes de datos.
- Carga incremental
 - Mover solo los cambios desde la última carga.
 - Se realiza periódicamente después del inicio de DW.
 - Menos pesado - volúmenes de datos más pequeños.
- Las dimensiones deben actualizarse **antes** que los hechos.



Workflow

Diseño Físico
DW


Proceso ETL

Extracción

Transformación

Carga

SuperStore Workflow





Índice

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

1 Diseño Físico DW

2 Proceso ETL

3 Extracción

4 Transformación

5 Carga



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Full Extraction

Los datos son extraídos completamente desde las fuentes de datos. Debido a que esta extracción refleja todos los datos actualmente disponibles en las fuentes de datos, no hay necesidad de mantener un seguimiento de los cambios en la fuente de datos desde la última extracción exitosa.

Incremental Extraction

Sólo se extraen los datos que han cambiado desde un momento bien definido del tiempo. Este momento puede corresponder a la última extracción realizada o un evento empresarial más complejo.



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Full Extraction

Los datos son extraídos completamente desde las fuentes de datos. Debido a que esta extracción refleja todos los datos actualmente disponibles en las fuentes de datos, no hay necesidad de mantener un seguimiento de los cambios en la fuente de datos desde la última extracción exitosa.

Incremental Extraction

Sólo se extraen los datos que han cambiado desde un momento bien definido del tiempo. Este momento puede corresponder a la última extracción realizada o un evento empresarial más complejo.



Extracción

Full Extraction

Los datos son extraídos completamente desde las fuentes de datos. Debido a que esta extracción refleja todos los datos actualmente disponibles en las fuentes de datos, no hay necesidad de mantener un seguimiento de los cambios en la fuente de datos desde la última extracción exitosa.

Incremental Extraction

Sólo se extraen los datos que han cambiado desde un momento bien definido del tiempo. Este momento puede corresponder a la última extracción realizada o un evento empresarial más complejo.



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Seguimiento del cambio (delta):

- *Timestamps*
- *Partitioning*
- *Triggers*
- *Change Data Capture*



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Seguimiento del cambio (delta):

- *Timestamps*
- *Partitioning*
- *Triggers*
- *Change Data Capture*



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Seguimiento del cambio (delta):

- *Timestamps*
- *Partitioning*
- *Triggers*
- *Change Data Capture*



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Seguimiento del cambio (delta):

- *Timestamps*
- *Partitioning*
- *Triggers*
- *Change Data Capture*



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Seguimiento del cambio (delta):

- *Timestamps*
- *Partitioning*
- *Triggers*
- *Change Data Capture*




Extracción

Partition Tables

List
Partitioning



Range
Partitioning



Hash
Partitioning





Extracción

Partition Tables

```
ALTER TABLE earthquake MODIFY
PARTITION BY RANGE (occurred_on)
(
PARTITION earthquakes1960
VALUES LESS THAN (TO_DATE('01/01/1970','DD/MM/YYYY')),
PARTITION earthquakes1970
VALUES LESS THAN (TO_DATE('01/01/1980','DD/MM/YYYY')),
PARTITION earthquakes1980
VALUES LESS THAN (TO_DATE('01/01/1990','DD/MM/YYYY')),
PARTITION earthquakes1990
VALUES LESS THAN (TO_DATE('01/01/2000','DD/MM/YYYY')),
PARTITION earthquakes2000
VALUES LESS THAN (TO_DATE('01/01/2010','DD/MM/YYYY')),
PARTITION earthquakes2010
VALUES LESS THAN (TO_DATE('01/01/2020','DD/MM/YYYY')))

select *
from earthquake partition(earthquakes1990)
```



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

On line Extraction

Los datos son directamente extraídos desde el sistema fuente (accediendo directamente a las tablas de datos o a un sistema intermedio) (*DBLink, Oracle GoldenGate, ...*)

Off line Extraction

Los datos no son directamente extraídos desde el sistema fuente, si no almacenados explícitamente fuera de este (*flat files, dump files, logs, transportable tablespaces, external tables, ...*)



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

On line Extraction

Los datos son directamente extraídos desde el sistema fuente (accediendo directamente a las tablas de datos o a un sistema intermedio) (*DBLink, Oracle GoldenGate, ...*)

Off line Extraction

Los datos no son directamente extraídos desde el sistema fuente, si no almacenados explícitamente fuera de este (*flat files, dump files, logs, transportable tablespaces, external tables, ...*)



Extracción

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

On line Extraction

Los datos son directamente extraídos desde el sistema fuente (accediendo directamente a las tablas de datos o a un sistema intermedio) (*DBLink, Oracle GoldenGate, ...*)

Off line Extraction


Los datos no son directamente extraídos desde el sistema fuente, si no almacenados explícitamente fuera de este (*flat files, dump files, logs, transportable tablespaces, external tables, ...*)



External Tables

```
SELECT *  
FROM EMP
```

External table





Extracción

External Tables

```
create or replace directory dirxe as 'C:\tmp';
```


```
CREATE TABLE saludos_ext (  
    id number,  
    saludo varchar2(20)  
)  
ORGANIZATION EXTERNAL (  
    TYPE ORACLE_LOADER  
    DEFAULT DIRECTORY dirxe  
    ACCESS PARAMETERS (  
        RECORDS DELIMITED BY NEWLINE  
        FIELDS TERMINATED BY ','  
        MISSING FIELD VALUES ARE NULL  
    )  
    LOCATION ('saludos.txt')  
)
```

```
select * from saludos_ext;
```



Extracción

DBLinks



Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Extracción

DBLinks

```
CREATE PUBLIC DATABASE LINK sbduta
CONNECT TO rvaldivia IDENTIFIED BY 123
USING '(description =
      (address =
        (protocol = tcp)
        (host = 146.83.109.225)
        (Port = 1521))
      (connect_data =
        (sid = sbduta))
    )';
```

```
select * from saludos@sbduta
```

Diseño Físico
DW

Proceso ETL


Extracción

Transformación

Carga



Materialized Views





Extracción

Materialized View

```
CREATE MATERIALIZED VIEW saludos_mv
BUILD IMMEDIATE
REFRESH FORCE
ON DEMAND
AS
SELECT * FROM saludos@sbduta;

-- En la instancia master
CREATE MATERIALIZED VIEW LOG ON rvaldivia.saludos
TABLESPACE users
WITH PRIMARY KEY
INCLUDING NEW VALUES;
--


EXEC DBMS_MVIEW.refresh('saludos_mv');

select * from saludos_mv
```



Extracción

GoldenGate ¹



¹<https://www.paradigmadigital.com/dev/que-es-oracle-goldengate/>



Índice

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

1 Diseño Físico DW

2 Proceso ETL

3 Extracción

4 Transformación

5 Carga



Transformación

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformaciones usuales:

- Conversiones de tipos de datos
- Normalización – desnormalización
- Claves de producción a claves subrogadas



Transformaciones usuales:

- Conversiones de tipos de datos
- Normalización — desnormalización
- Claves de producción a claves subrogadas



Transformación

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformaciones usuales:

- Conversiones de tipos de datos
- Normalización — desnormalización
- Claves de producción a claves subrogadas



Transformación

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

Transformaciones usuales:

- Conversiones de tipos de datos
- Normalización — desnormalización
- Claves de producción a claves subrogadas



Transformación

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- No usar valores “especiales” (e.d., 0, -1) en los datos de las dimensiones
Estos son difíciles de entender en operaciones de consulta/análisis.
- Marcar los hechos con una dimensión de “*Data Quality*”
normal, anormal, fuera de los límites, imposible, ...

- Tratamiento de valores NULL

Uso de nulos sólo para valores de medidas (cuidado).

Uso de un registro de dimension especial para valores desconocidos/no aplicables.

Por ejemplo, para la dimensión de tiempo, en vez de NULL, use una clave especial para representar “Dato no conocido”,

Evita problemas en *joins*.



Transformación

- No usar valores “especiales” (e.d., 0, -1) en los datos de las dimensiones
Estos son difíciles de entender en operaciones de consulta/análisis.

- Marcar los hechos con una dimensión de “*Data Quality*”
normal, anormal, fuera de los límites, imposible, ...

- Tratamiento de valores NULL

Uso de nulos sólo para valores de medidas (cuidado).

Uso de un registro de dimension especial para valores desconocidos/no aplicables.

Por ejemplo, para la dimensión de tiempo, en vez de NULL, use una clave especial para representar “Dato no conocido”,

Evita problemas en *joins*.

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga



Transformación

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- No usar valores “especiales” (e.d., 0, -1) en los datos de las dimensiones
Estos son difíciles de entender en operaciones de consulta/análisis.
- Marcar los hechos con una dimensión de “*Data Quality*”
normal, anormal, fuera de los límites, imposible, ...

- Tratamiento de valores NULL

Uso de nulos sólo para valores de medidas (cuidado).

Uso de un registro de dimension especial para valores desconocidos/no aplicables.

Por ejemplo, para la dimensión de tiempo, en vez de NULL, use una clave especial para representar “Dato no conocido”,

Evita problemas en *joins*.



Transformación

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- No usar valores “especiales” (e.d., 0, -1) en los datos de las dimensiones
Estos son difíciles de entender en operaciones de consulta/análisis.
- Marcar los hechos con una dimensión de “*Data Quality*”
normal, anormal, fuera de los límites, imposible, ...
- Tratamiento de valores NULL
Uso de nulos sólo para valores de medidas (cuidado).
Uso de un registro de dimension especial para valores desconocidos/no aplicables.

Por ejemplo, para la dimensión de tiempo, en vez de NULL, use una clave especial para representar “Dato no conocido”,

Evita problemas en *joins*.



Índice

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

1 Diseño Físico DW

2 Proceso ETL

3 Extracción

4 Transformación

5 Carga



Carga

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Cargas offline vs Cargas online.
- No verificar restricciones de integridad (debería asegurarse en el proceso ETL).
- Utilizar tablas de índice para mejorar los accesos, pero no habilitar durante el proceso de carga.
- La tabla de hechos es una buena candidata para particionamiento.



- Cargas offline vs Cargas online.
- No verificar restricciones de integridad (debería asegurarse en el proceso ETL).
- Utilizar tablas de índice para mejorar los accesos, pero no habilitar durante el proceso de carga.
- La tabla de hechos es una buena candidata para particionamiento.



Carga

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Cargas offline vs Cargas online.
- No verificar restricciones de integridad (debería asegurarse en el proceso ETL).
- Utilizar tablas de índice para mejorar los accesos, pero no habilitar durante el proceso de carga.
- La tabla de hechos es una buena candidata para particionamiento.



Carga

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Cargas offline vs Cargas online.
- No verificar restricciones de integridad (debería asegurarse en el proceso ETL).
- Utilizar tablas de índice para mejorar los accesos, pero no habilitar durante el proceso de carga.
- La tabla de hechos es una buena candidata para particionamiento.



Carga

Diseño Físico
DW

Proceso ETL

Extracción

Transformación

Carga

- Cargas offline vs Cargas online.
- No verificar restricciones de integridad (debería asegurarse en el proceso ETL).
- Utilizar tablas de índice para mejorar los accesos, pero no habilitar durante el proceso de carga.
- La tabla de hechos es una buena candidata para particionamiento.